

c-VEP のニューラルデコーディング

鷺沢研究室 佐藤純一

April 18, 2016

- PN 系列 (Pseudo Noise; 擬似雑音系列) を利用
- t-VEP や f-VEP に比べて高い情報転送量 (ITR)




図 1: PN 系列と視覚刺激の対応

- 特徴抽出：空間フィルタ
- 識別：テンプレートマッチング




図 2: c-VEP BCI の流れ

空間フィルタ

空間フィルタ

- $x_i[t]$: i チャンネルの c-VEP ($i = 1, \dots, I$)

$$y[t] = \sum_{i=1}^I w_i x_i[t]$$

従来手法 **CCA** による空間フィルタ

- \mathbf{X}_k : k 番目の訓練行列
 - (i, n) 要素 : $x_i[n]$
- $\mathbf{R} = \frac{1}{K} \sum_{k=1}^K \mathbf{X}_k$
- CCA 空間フィルタは以下の最適化問題における w_x

$$\max_{w_x, w_r} \frac{\sum_{k=1}^K w_x^\top \mathbf{X}_k \mathbf{R}^\top w_r}{\sqrt{\sum_{k=1}^K w_x^\top \mathbf{X}_k \mathbf{X}_k^\top w_x \cdot w_r^\top \mathbf{R} \mathbf{R}^\top w_r}}.$$

CCA 空間フィルタの問題点

- CCA 空間フィルタの重みは訓練データ X_k と R のみで決定
- 提示された PN 系列の情報を用いていない
 - PN 系列の性質（低い自己相関）を持っているとは限らない
- c-VEP の性質を取り入れることで性能を向上させる

ニューラルデコーディング

- 脳信号からオリジナルの刺激を取り出す
- 本研究では、c-VEP を PN 系列（提示刺激）に近づける
 - 目標変数（target）に PN 系列を用いた最適化




図 3: ニューラルデコーディング

時空間の逆フィルタ

- $w_{i,\tau}$: 時空間フィルタの重み
- τ_0 : 視覚刺激から c-VEP の誘発までの時間ラグ
- N_τ : フィルタのタップ長
- 逆フィルタの出力信号 $y[n]$ は以下で表される

$$y[n] = \sum_{i=1}^I \sum_{\tau=0}^{N_\tau-1} w_{i,\tau} x_i[n + \tau + \tau_0]$$

- 逆フィルタを設計するため, $+\tau$ とする

線形逆フィルタ least mean square error (LMSE)

- $s[n]$: PN 系列
 - 直流成分除去のため中心化（平均を 0 にする）
 - 脳信号とサンプリング周波数を合わせるためアップサンプル
 - $s[n] \in \{-0.5, +0.5\}$, $n = 0, \dots, N - 1$
- $y[n]$ と $s[n]$ の 2 乗誤差を最小化

$$\min_w \sum_{n=0}^{N-1} (y[n] - s[n])^2.$$

正規方程式

- $\mathbf{X} \in \mathbb{R}^{N \times M}$: EEG, N はサンプル数, $M = N_\tau N_{\text{ch}}$ は特徴量の次元数
- $y^{(n)} = \sum_{m=0}^{M-1} w_m x_m^{(n)}$ とおくと, 目的関数は以下で表される

$$J(w) = \frac{1}{N} \sum_{n=0}^{N-1} \left(\sum_{m=0}^{M-1} w_m x_m^{(n)} - s^{(n)} \right)^2$$

- $k = 0, \dots, M-1$ のとき, k で偏微分して最小化する

$$\frac{\partial J(w)}{\partial w_k} = \frac{2}{N} \sum_{n=0}^{N-1} \left(\sum_{m=0}^{M-1} w_m x_m^{(n)} - s^{(n)} \right) x_k^{(n)} = 0$$

$$\sum_{n=0}^{N-1} \sum_{m=0}^{M-1} x_k^{(n)} x_m^{(n)} w_m - \sum_{n=0}^{N-1} x_k^{(n)} s^{(n)} = 0$$

- したがって

$$\mathbf{X}^\top \mathbf{X} \mathbf{w} - \mathbf{X}^\top \mathbf{s} = 0$$

$$\mathbf{w} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{s}$$

線形逆フィルタ lasso

- N_τ を大きくすると w の要素数が増加し過学習しやすい
- l_1 ノルム正則化で疎な解を得ることができる

$$\min_w \sum_{n=0}^{N-1} (y[n] - s[n])^2 + \alpha \sum_{i=1}^I \sum_{\tau=0}^{N_\tau-1} |w_{i,\tau}|,$$




図 4: 誤差関数の等高線と lasso の制約条件

非線形逆フィルタ

- c-VEP は PN 系列の非線形変換
 - PN 系列による刺激が脳内を通過して発生
- 線形モデルでは表現に限界がある

→ 非線形モデルによりニューラルデコーディングを行う

線形モデル

- 線形回帰 (LMSE, lasso)
- ロジスティック回帰

非線形モデル

- ニューラルネットワーク
- カーネル回帰
- Support Vector Machine (SVM)

ニューラルネットワーク (NN)

- 入力層, 中間層, 出力層をもつ
- 情報が入力から出力に伝搬する構造をもつ
- この研究では4層(2つの中間層)をもつNNを利用




図 5: 4層ニューラルネットワーク

NN による非線形逆フィルタ

- J_1, J_2, J_3 : 入力層, 中間層 1, 中間層 2 の次元
- $\mathbf{W}_1 \in \mathbb{R}^{J_2 \times J_1}, \mathbf{W}_2 \in \mathbb{R}^{J_3 \times J_2}, \mathbf{w}_3 \in \mathbb{R}^{J_3 \times 1}$:
中間層 1, 中間層 2 の重み行列, 出力層の重みベクトル
- $\mathbf{b}_1 \in \mathbb{R}^{J_2}, \mathbf{b}_2 \in \mathbb{R}^{J_3}, b_3 \in \mathbb{R}$: 各層のバイアス
- 中間層の活性化関数に以下の ReLU を用いる

$$f(u) = \max(u, 0)$$

- 出力層の活性化関数に \tanh を用いる
 - 値域 $(-1, 1)$

$$g(u) = \tanh(u)$$

- 中間層と出力層の出力はそれぞれ以下の式で表される

$$z_n^1 = f(\mathbf{W}_1 \mathbf{x}_n + \mathbf{b}_1)$$

$$z_n^2 = f(\mathbf{W}_2 z_n^1 + \mathbf{b}_2)$$

$$y_n = g(\mathbf{w}_3^\top z_n^2 + b_3)$$

- \mathbf{w} を $\mathbf{w}_1, \mathbf{W}_2, \mathbf{w}_3, \mathbf{b}_1, \mathbf{b}_2, \mathbf{b}_3$ の成分 (M 個) をもつベクトルとする
- パラメータは 2 乗誤差最小化によって決定される

$$\min_{\mathbf{w}} E(\mathbf{w}) = \sum_{n=0}^{N-1} (s[n] - y_n)^2$$

勾配降下法

- $E(\boldsymbol{w})$ は凸関数ではなく，極小点は一般に多数存在する
- $E(\boldsymbol{w})$ の局所的な極小点 \boldsymbol{w} を求める
- $E(\boldsymbol{w})$ の勾配は以下で定義される

$$\nabla E(\boldsymbol{w}) \equiv \frac{\partial E}{\partial \boldsymbol{w}} = \left[\frac{\partial E}{\partial w_1} \cdots \frac{\partial E}{\partial w_M} \right]^\top$$

- 現在の重みを $\boldsymbol{w}^{(t)}$ ，動かした後の重みを $\boldsymbol{w}^{(t+1)}$ とする
- \boldsymbol{w} の初期値を決め，**勾配降下法**は以下のように重み \boldsymbol{w} を更新する

$$\boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} - \epsilon \nabla E$$

- ϵ は学習率（learning rate）であり，更新量の大きさを定める

確率的勾配降下法 (SGD; stochastic gradient descent)

- 訓練サンプル $n = 1, \dots, N$ のうち一部だけをつかってパラメータを更新する
- 1つのミニバッチ（少数の訓練集合）を \mathcal{D}_t とする
 - t 回目の更新毎にサンプル集合が変わる
- \mathcal{D}_t の全サンプルに対する誤差を計算し、パラメータを更新する

$$E_t(\mathbf{w}) = \frac{1}{N_t} \sum_{n \in \mathcal{D}_t} E_n(\mathbf{w})$$

- ここで、 $N_t = |\mathcal{D}_t|$ はミニバッチのサンプル数
- SGD を使うと局所的な極小解にトラップされるリスクが低減する
 - 目的関数 $E_t(\mathbf{w})$ が更新ごとに異なるため

誤差逆伝搬法 (1)

- ユニット i から j へ入力のリ重み付き線形和を u_j とおく

$$u_j = \sum_i w_{ji} z_i$$

- 活性化関数 $h(\cdot)$ を用いたとき, j での出力は

$$z_j = h(u_j)$$

- 誤差 $\delta_j \equiv \frac{\partial E}{\partial u_j}$ を導入する
- 偏微分の連鎖法則から以下の逆伝搬公式が得られる

$$\delta_j = h'(u_j) \sum_k w_{kj} \delta_k$$

誤差逆伝搬法 (2)

誤差逆伝搬法

- ① 入力ベクトル x_n を $u_j = \sum_i w_{ji} z_i$, $z_j = h(u_j)$ で順伝搬させる
- ② 出力ユニットの誤差 $\delta_k = \partial E_n / \partial u_k$ を求める
- ③ $\delta_j = h'(u_j) \sum_k w_{kj} \delta_k$ で δ を逆伝搬させる
- ④ $\frac{\partial E_n}{\partial w_{ji}} = \delta_j z_i$ で微分を計算する




図 6: 逆伝搬

誤差逆伝搬法 (3)

- $f(u) = \max(0, u)$ は $u = 0$ で微分不可能であるが, $u = 0$ において $[0, 1]$ の任意の値を置くことで微分可能なものとする (劣微分)

$$f'(u) = \begin{cases} 1 & (u \leq 0) \\ 0 & (\text{otherwise}) \end{cases}$$

- $g(u) = \tanh(u)$ のとき

$$g'(u) = 1 - g(u)^2$$

- 多層ニューラルネットのユニットを確率的に選別して学習する
- 中間層と入力層のユニットを確率 p でランダムに選出する
- ユニットの選出は重みを更新するたびに行う
- 学習終了後はすべてのユニットを使って順伝搬計算を行う
 - ドロップアウトの対象ユニットは重みを p 倍する
- 学習時にネットワークの自由度を下げることで、過学習を避ける
- ネットワークを独立に訓練し、推論時に結果を平均するのと同じ効果がある

実験

環境

- 20~22 歳までの健康な男性 5 人
- EEG は 16ch, 600Hz で計測し, 120Hz にダウンサンプリング
- PN 系列を 60Hz から 120Hz にアップサンプリング
- 180 サンプルでトレーニング, 288 サンプルでテスト

手法

- ① CCA 空間フィルタ (従来手法)
- ② 線形時空間逆フィルタ LMSE,
- ③ 線形時空間逆フィルタ lasso,
- ④ ニューラルネットによる非線形逆フィルタ

評価基準

- ① 入力の正確さ: classification accuracy
- ② デコードの復元度: 相関係数

デコード結果

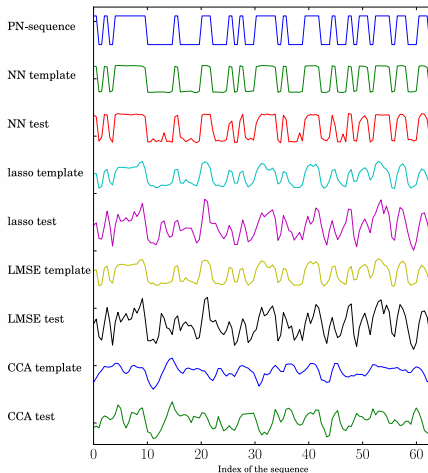


図 7: 被験者 1 のデコード波形




図 8: 被験者 1~5 の識別率

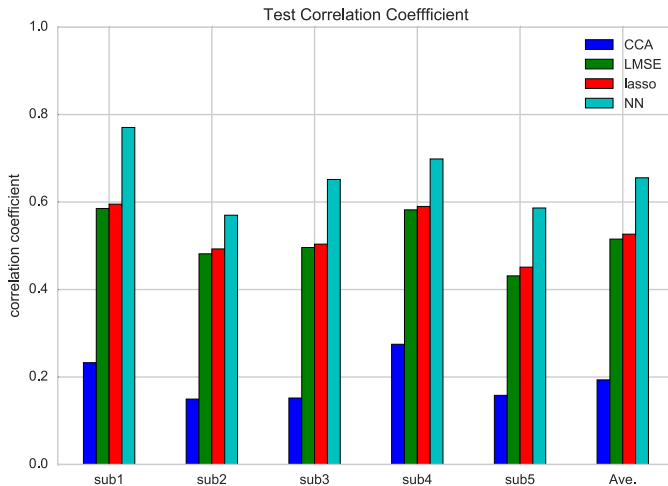


図 9: 被験者 1~5 の $s[n]$ と $y[n]$ の相関係数

- デコード性能の改善しても必ずしも識別率は向上しない
 - NN が最も高い相関
 - lasso が最も高い識別率
- 今回は NN は相関を最大化したが、識別率最大化でパラメータを選べば改善すると考えられる

まとめと今後の課題

まとめ

- 線形, 非線形の逆フィルタの提案
 - LMSE
 - lasso
 - Neural Network
- 提案法はいずれも高精度にデコードした
- CCA 空間フィルタよりも高い識別率, PN 系列との高い相関を示した

今後の課題

- PN 系列以外の系列を利用
- Recurrent Neural Network の適用
 - 再帰的構造をもつニューラルネットワーク